

Assignment 3: Kaggle Practice

本次作業的主要目的在讓同學練習 Kaggle 平台的操作，以及學習如何從給定資料中進行特徵分析與預測建模，作業使用的競賽連結為：

<https://www.kaggle.com/c/amazon-employee-access-challenge>

請同學建立模型，並預測目標欄位 **ACTION**。

1) 題目描述

When an employee at any company starts work, they first need to obtain the computer access necessary to fulfill their role. This access may allow an employee to read/manipulate resources through various applications or web portals. It is assumed that employees fulfilling the functions of a given role will access the same or similar resources. It is often the case that employees figure out the access they need as they encounter roadblocks during their daily work (e.g., not able to log into a reporting portal). A knowledgeable supervisor then takes time to manually grant the needed access in order to overcome access obstacles. As employees move throughout a company, this access discovery/recovery cycle wastes a nontrivial amount of time and money.

There is a considerable amount of data regarding an employee's role within an organization and the resources to which they have access. Given the data related to current employees and their provisioned access, models can be built that automatically determine access privileges as employees enter and leave roles within a company. These auto-access models seek to minimize the human involvement required to grant or revoke employee access.

2) 目標

The objective of this competition is to build a model, learned using historical data, that will determine an employee's access needs, such that manual access transactions (grants and revokes) are minimized as the employee's attributes change over time. The model will take an employee's role information and a resource code and will return whether or not access should be granted.

3) 題目說明

此競賽的目標是利用歷史資料建立一個預測模型，來判斷員工在特定職位與資源條件下，是否應被授予存取權限。

- 輸入：員工角色相關資訊
- 輸出：是否授權 (ACTION = 1 或 0)
- 評估方法: AUC

4) 特徵值

訓練資料包含以下欄位：

- **ACTION**：是否授權 (1 = 該資源存取申請被核准，0 = 未核准)
- **RESOURCE**：每個資源的識別 ID
- **MGR_ID**：該員工所屬主管的員工 ID；一位員工在同一時間只會有一位主管
- **ROLE_ROLLUP_1**：公司角色群組分類 ID 1 (例如：美國工程部)
- **ROLE_ROLLUP_2**：公司角色群組分類 ID 2 (例如：美國零售部)
- **ROLE_DEPTNAME**：公司角色所屬部門 (例如：零售部門)
- **ROLE_TITLE**：公司職稱描述 (例如：資深工程零售經理)
- **ROLE_FAMILY_DESC**：角色家族的延伸描述 (例如：零售經理、軟體工程)
- **ROLE_FAMILY**：角色家族描述 (例如：零售經理)
- **ROLE_CODE**：角色代碼；每個角色對應唯一的代碼 (例如：經理)

本資料中的特徵皆以 “ID” 形式表示，而非文字描述。也就是說相同編號代表相同類別，但是數值大小本身沒有意義，因此，如何處理類別型資料，是本作業的重要重點 (可以自行查找 feature engineering 內 target encoding 或 count encoding 的相關介紹，也許會有幫助)。

5) 作業要求

演算法不限，可使用課堂介紹方法或自行設計方法，至少要有 **3 次** 的 kaggle submission。

書面報告內需包含以下但不限於：

- (a) 資料前處理 (特徵值分析)
- (b) 模型訓練流程 (模型選用以及參數設定)
- (c) 模型評估 (kaggle score, cross-validation 選擇參數等)
- (d) 模型改進流程
 - 每次 submission 的修改內容
 - 修改原因
 - kaggle score (**public** and **private**) 的變化與分析造成變化的可能原因
- (e) 每次 submission 截圖紀錄

6) 評分標準 (此次作業評分的重點在於分析模型訓練過程以及透過 feature engineering、調整模型參數或使用不同的模型修正)

- (a) 資料前處理: 20%
- (b) 單次模型訓練流程與參數設定: 每次 submission 20%, 最多 60%
- (c) 每次 submission 之間的改進與分析可能造成的原因: 20%

7) 繳交內容: 書面報告 (PDF) 與程式碼，請合併成一個 zip 檔。**此次作業最多可以三位同學一組，繳交的 zip 檔名稱打上每一位組員的學號，並且每一位組員都須繳交一份檔案。**